# La nouvelle norme *Records in Contexts*: un modèle conceptuel et une ontologie OWL pour la description des archives

Support de formation distribué sous licence Creative Commons CC-By-SA 4.0.

Préparé par Florence Clavaud

(Archives nationales, Lab | Conseil international des Archives, groupe d'experts EGAD;

courriel : florence.clavaud@culture.gouv.fr)

pour les étudiants du Master 2 TNAH de l'Ecole nationale des Chartes (cours ENC 2551 sur la description des archives)

Date: mars 2023

#### Contenu

- 1. Records in Contexts : informations générales (rappels)
- 2. Le modèle conceptuel RiC-CM (rappels)
- 3. L'ontologie RiC-O
- 4. RiC-O aux Archives nationales
- 5. Exercices : produire et utiliser des données RDF/RiC-O
- 6. Conclusion

#### **Quelques précisions pour commencer**

#### Vous savez déjà :


- Ce que sont les **archives**
- Quels sont les **standards qui encadrent actuellement la description archivistique**, et en particulier ce qu'il faut absolument retenir de la norme principale (dont le nom est ?)
- Quels sont les **formats techniques existants qui correspondent à ces normes**, et en gros ce qu'ils permettent
- Ce que c'est qu'un modèle conceptuel
- Comment s'appelle **le nouveau modèle conceptuel pour la description des archives**, et quelles sont ses grandes lignes. Il vous a été présenté assez précisément en novembre 2022 (voir le support de cours dans le dépôt sur GitHub)
- Ce que c'est que le web de données, RDF et une ontologie

#### À la fin de ce cours, vous devriez :

- Connaître l'essentiel du standard RiC et des raisons et enjeux de l'évolution des pratiques de la description archivistique
- Avoir une vision globale de RiC-O
- Disposer de repères pour réfléchir à une stratégie de mise en œuvre de RiC-O et pour produire des données RDF à partir de métadonnées archivistiques existantes (notamment, comment passer d'EAD à RDF)



# 1. Records in Contexts (RiC): informations générales (petits rappels)





# Records in Contexts (RiC), un standard en quatre parties


- un court document d'**introduction à la description archivistique** (RiC-Introduction to Archival Description ou RiC-IAD)
- Un modèle conceptuel abstrait, indépendant de toute implémentation (RiC-Conceptual Model ou RiC-CM)
- Une ontologie OWL, transposition de RiC-CM, pour définir le vocabulaire et les règles applicables aux métadonnées archivistiques conformes à RiC et ayant la forme de jeux de données RDF (RiC-Ontology ou RiC-O)
- Un **manuel de mise en œuvre** (RiC-Application Guidelines, RiC-AG)



#### **Records in Contexts: pourquoi?**

Pour remplacer les quatre standards internationaux existants





Pour passer de principes et règles de description à

#### une norme unique fondée sur une approche entités-relations

- Pour mieux représenter les archives, leur histoire et les multiples couches de contextes dans lesquelles elles s'inscrivent
- Pour permettre aux archivistes et aux records managers de passer à une description plus précise, plus nuancée, plus facile à exploiter, multidimensionnelle
- Et pour, de ce fait, faciliter l'accès aux métadonnées archivistiques donc aux ressources documentaires qu'elles décrivent

Cf. la transition en cours des métadonnées bibliographiques vers des graphes de données (modèle IFLA-LRM et nouvelles règles de catalogage RDA)




# Records in Contexts : voir le monde des archives comme un graphe orienté (exemple)

A gauche, la vue HTML, dans la SIV des Archives nationales, de l'inventaire du fonds de la famille Vitet conservé aux AN sous la cote 572AP (source : un fichier EAD) https://www.siv.archives-nationales.culture.gouv.fr/siv/IR/FRAN\_IR\_003500

A droite, les informations de haut niveau du même inventaire, après conversion en RDF/RiC-O et import dans un triplestore RDF (image source disponible ici : https://raw.githubusercontent.com/ICA-EGAD/RiC-O/master/examples\_v0-2/NationalArchivesOfFrance/GraphDB-screenshot\_recordResource-003500-top\_FondsVitet\_vRiC-O-0-2.jpg)







#### RiC est développé par le groupe EGAD

- EGAD: Expert Group on Archival Description (voir https://www.ica.org/en/egad-steering-committee-0)
- Un des groupes d'experts du Conseil international des Archives (ICA)
- Mandat : 2013-2016, renouvelé depuis
- Actuellement 21 personnes, venant de 14 pays (renouvellement partiel fin décembre 2022) ; différentes fonctions et compétences, différents points de vue
- Tous les discussions et travaux sont menés en anglais
- Travail déjà plusieurs fois soumis à commentaires pour faire participer les communautés professionnelles concernées
- Devra impérativement être poursuivi en continu ensuite



#### Historique et feuille de route globale de RiC

- Août 2016 : **publication de RiC-CM 0.1** avec un appel à commentaires

  Entre août 2016 et janvier 2017, EGAD a reçu de très nombreux commentaires, et les a pris en compte depuis
- Février-novembre 2019 : plusieurs versions beta de RiC-O successivement envoyées aux personnes qui avaient répondu à un appel à commentateurs
- 12 décembre 2019 : publication d'une première version officielle de l'ontologie, RiC-O 0.1
   (https://www.ica.org/standards/RiC/ontology) assortie d'un appel à commentaires ; publication
   d'une prévisualisation de RiC-CM 0.2 qui remplace RiC-CM 0.1 devenu obsolète
- Mars 2020 : ouverture de l'entrepôt de sources de RiC-O sur GitHub
- 12 février 2021 : **publication de RiC-O 0.2**, qui remplace RiC-O 0.1 (toujours à **https://www.ica.org/standards/RiC/ontology)** et qui est conforme à RiC-CM 0.2
- Juillet 2021 : **publication du modèle conceptuel RiC-CM 0.2** ; appel à commentaires
- Janvier 2022 : **publication de RiC-IAD**

La publication de la version 1.0 de RiC, qui aura le statut de recommandation officielle de l'ICA, est prévue pour le premier semestre 2023.

Toutes les versions de RiC antérieures à la v1.0 sont par définition des *drafts* (projets). Cependant **RiC-CM et RiC-O 0.2 sont proches de cette future version 1.0 et peuvent déjà être employés**.




#### Comment se tenir au courant des avancées de RiC?

Les principales actualités sur RiC sont publiées sur le **site web du CIA**.

- Sur RiC-CM: surveiller le site web du CIA et les listes professionnelles françaises de discussion des archivistes (AAF, SIAF), ou la liste de l'association Humanistica
- Sur RiC-O:
  - Consulter régulièrement le site web officiel de RiC-O, qui fournit également des informations sur les projets, événements et outils
  - Si on souhaite récupérer le dernier état de RiC-O, des exemples, participer aux discussions et travaux en cours : consulter l'entrepôt de sources sur GitHub
  - Il est possible de s'abonner à une liste des utilisateurs de RiC-O
- **Ne pas hésiter à me contacter** par courriel (florence.clavaud@culture.gouv.fr), pour toute question, remarque, demande de conseil ou de présentation



#### 2. Le modèle conceptuel RiC-CM (rappels)





#### **RiC-CM définit et organise 22 entités**

Les entités dans un modèle conceptuel sont les **principaux objets d'intérêt du domaine envisagé**. Les entités identifiées dans RiC-CM sont celles qui permettent de fournir les éléments de contexte nécessaires pour la gestion physique, la conservation, la découverte, l'utilisation et la compréhension des documents d'archives. Les quatre entités considérées comme essentielles sont indiquées en gras dans le tableau cidessous (Record Resource, Instantiation, Agent, Activity). Les entités sont organisées en hiérarchie d'objets. Les attributs et relations d'une entité de haut niveau sont héritées par les entités de niveau inférieur.

RiC Entities Hierarchy						
First Level	Second Level	Third Level	Fourth Level			
RiC-E01 Thing	RiC-E02 Record Resource	RiC-E03 Record Set				
		RiC-E04 Record				
		RiC-E05 Record Part				
	RiC-E06 Instantiation					
	RiC-E07 Agent	RiC-E08 Person				
		RiC-E09 Group	RiC-E10 Family			
			RiC-E11 Corporate Body			
		RiC-E12 Position				
		RiC-E13 Mechanism				
	RiC-E14 Event	RiC-E15 Activity				
	RiC-E16 Rule	RiC-E17 Mandate				
	RiC-E18 Date	RiC-E19 Single Date				
		RiC-E20 Date Range				
		RiC-E21 Date Set				
	RiC-E22 Place					



#### Les entités RiC-CM ont des attributs

#### Il y a 41 attributs:

- Des attributs communs à toutes les entités : identifier, name, descriptive note
- Des attributs pour chacune des entités de haut niveau (les sous-entités « héritent » de ces attributs)
- Des attributs propres à certaines entités

Certains attributs sont répétables ou extensibles.

ID	Assigned identifier beginning with <b>RIC-A</b> and followed by a number.		
Name	Natural language label.		
Definition	Brief definition.		
Domain	Entity or Entities which may have the Attribute		
Specifications	The possible specifications, precisions, annotations or qualifiers of the meaning of the value		
	an attribute in a description.		
Extensibility	The possible differentiation of the attribute using extensions or specializations in sub-		
	attributes.		
Repeatability	Whether the attribute can be repeated or not in the description of a particular entity or		
	relation.		
Value Schema	The rules for selecting or formulating the value of the attribute.		
Scope	It provides additional information to understand and use the attribute.		
Examples	It presents examples of application of each attribute.		



## **Exemple : les attributs des entités RiC-E04 Record et de RiC-E06 Instantiation**

RiC-E04	Record	
Attribute ID	Attribute Name	
RiC-A16	Descriptive Note	
RiC-A22	Identifier	
RiC-A28	Name	
RiC-A21	History	
RiC-A35	Record Resource Extent	
RiC-A38	Scope and content	
RiC-A40	Structure	
RiC-A03	Authenticity Note	
RiC-A07	Classification	
RiC-A08	Conditions of Access	
RiC-A09	Conditions of Use	
RiC-A10	Content Type	
RiC-A17	Documentary Form Type	
RiC-A24	Integrity	
RiC-A25	Language	
RiC-A26	Legal Status	
RiC-A39	State	

RiC-E06	Instantiation	
Attribute ID	Attribute Name	
RiC-A16	Descriptive Note	
RiC-A22	Identifier	
RiC-A28	Name	
RiC-A03	Authenticity Note	
RiC-A04	Carrier Extent	
RiC-A05	Carrier Type	
RiC-A08	Conditions of Access	
RiC-A09	Conditions of Use	
RiC-A21	History	
RiC-A23	Instantiation Extent	
RiC-A24	Integrity	
RiC-A31	Physical Characteristics	
RiC-A33	Production Technique	
RiC-A34	Quality of Representation	
RiC-A37	Representation Type	
RiC-A40	Structure	



# Les entités RiC-CM sont reliées entre elles par des relations

Dans RiC-CM 0.2, il y a **78 relations** (et les relations inverses le cas échéant), organisées en **système poly- hiérarchique**. La relation de haut niveau est 'is related to'.

Elles ont des attributs (identifier, description, date, certainty, source).

- Whole-part relations
- Sequential and temporal relations
- Subject relations
- Record Resource to Record Resource relations
- Record Resource to Instantiation relations
- Provenance relations
- Instantiation to Instantiation relations
- Management relations
- Agent to Agent relations
- Event relations
- Rule relations


RESOURCE TO RECORD RESOURCE relations RIC-R022: Record RESOURCE is record resource resource RECORD RESOURCE RECORD RESOURCE RECORD RESOURCE	RiC-R023: Record resource has genetic link to Record Resource Record Resource	RiC-R010: Record is original of Record (see also above)  RiC-R011: Record is droft of Record (see also above)  RiC-R012: Record Resource has copy  Record Resource (see also above)	
	RiC-R013: Record Resource has reply Record Resource (see also above) RiC-R003: Record has or had constituent Record Part (see also above) RiC-R024: Record Set included Record or Record Set		
Type: <u>Record</u> <u>Resource to</u> <u>Instantiation</u> <u>relations</u>		3	97

Sommaire

15 / 53




### Les principales entités RiC-CM et quelques-unes des relations existantes





#### 3. L'ontologie RiC-O





#### RiC-O, qu'est-ce que c'est (rappel)?

- une ontologie OWL générique pour la description des archives et de leurs entités contextuelles
- une transposition formelle du modèle conceptuel Records in Contexts-Conceptual Model (RiC-CM)
  - totalement conforme avec RiC-CM 0.2
  - a joué et joue toujours un rôle majeur dans les tests relatifs au contenu et à la logique de RiC-CM (développement simultané)
  - o documentée en anglais, avec introduction détaillée et spécifications de chaque composant



#### RDF, RDFS, OWL

- RDF (Resource Description Framework ; une recommandation du W3C depuis 1999, version actuelle : RDF 1.1 ; voir http://www.w3.org/RDF/) ;
- RDFS (the RDF Schema language; une recommandation du W3C depuis 2004; voir http://www.w3.org/TR/rdf-schema/);
- OWL (Web Ontology Language, première version en 2004, 2e version (OWL 2) en 2009, avec une 2e édition en 2012 ; voir http://www.w3.org/2001/sw/wiki/OWL)

Une ontologie, en sciences de l'information, est un modèle de données représentatif d'un ensemble de concepts dans un domaine, et des relations entre ces concepts. Elle permet de raisonner à propos des objets du domaine concerné.

Voir aussi la définition de Gruber: "An ontology is an explicit specification of a conceptualization. [...] A conceptualization is an abstract, simplified view of the world that we wish to represent for some purpose." Thomas R. Gruber, Towards Principles for the Design of Ontologies Used for Knowledge Sharing in Formal Ontology in Conceptual Analysis and Knowledge Representation, Kluwer Academic Publishers, 1993, en ligne.



#### Principes d'élaboration de RiC-O

#### Disposer d'un modèle OWL qui soit :


- une transposition formelle de RiC-CM
- une **ontologie de référence**, de domaine
- immédiatement utilisable
- flexible
- utile
- extensible

#### Voir aussi:

- RiC-O design principles
- Why use RiC-O?



# RiC-O doit être utile : faire des recherches sur le graphe produit



Une requête SPARQL sur le graphe des producteurs d'archives des Archives nationales (actuellement, près de 16000 notices d'autorité en EAC-CPF) (copie d'écran d'une instance locale de GraphDB). On peut ainsi poser de nouvelles questions (en parcourant le graphe via les arcs/relations)



#### Accéder à RiC-O (pour les humains)

La version officielle de RiC-O (donc, en l'occurrence, RiC-O 0.2) est accessible via son URI: https://www.ica.org/standards/RiC/ontology.



Cet URI permet d'atteindre une représentation HTML de l'ontologie, qui donne à lire toute sa documentation interne, actuellement uniquement en anglais.

L'entrepôt de sources de RiC-O permet en outre de télécharger :

- la dernière version en date de RiC-O
- Des exemples
- Des diagrammes



#### Le fichier source de la version officielle de RiC-O

Pour le télécharger directement, utiliser le lien présent en haut de la vue HTML.

```
<?xml version="1.0" encoding="UTF-8"?>
<rdf:RDF xmlns="https://www.ica.org/standards/RiC/ontology#" 4
        xmlns:cc="http://creativecommons.org/ns#" xmlns:dc="http://purl.org/dc/elements/1.1/" 4
        xmlns:owl="http://www.w3.org/2002/07/owl#" 4
        xmlns:rdf="http://www.w3.org/1999/02/22-rdf-syntax-ns#" 4
        xmlns:xsd="http://www.w3.org/2001/XMLSchema#" xmlns:html="http://www.w3.org/1999/xhtml" &
        xmlns:rdfs="http://www.w3.org/2000/01/rdf-schema#" 4
        xmlns:rico="https://www.ica.org/standards/RiC/ontology#"4
        xmlns:skos="http://www.w3.org/2004/02/skos/core#" xmlns:vann="http://purl.org/vocab/vann/" 4
        xmlns:voaf="http://purl.org/vocommons/voaf#" xmlns:dcterms="http://purl.org/dc/terms/" بر
        xmlns:ric-dft="https://www.ica.org/standards/RiC/vocabularies/documentaryFormTypes#" 4
        xmlns:ric-rst="https://www.ica.org/standards/RiC/vocabularies/recordSetTypes#" 4
        xml:base="https://www.ica.org/standards/RiC/ontology">u
        <owl:Ontology rdf:about="https://www.ica.org/standards/RiC/ontology">
                 <cc:license rdf:resource="https://creativecommons.org/licenses/by/4.0/"/>
<
                 dc:contributor xml:lang="en">Aaron Rubinstein (University of Massachusetts Amherst, USA), ب
                          <dc:contributor xml:lang="en">Daniel Pitti (University of Virginia, USA), chair of 
                          EGAD</dc:contributor>4
                 <dc:contributor xml:lang="en">Miia Herrala (National Archives of Finland), member of \( \varphi \)
                          EGAD</dc:contributor>4
                 dc:contributor xml:lang="en">Tobias Wildi (Docuteam GmbH, Switzerland), member of با
                          EGAD</dc:contributor>4
                 dc:creator xml:lang="en">Florence Clavaud (Archives nationales de France), member of EGAD, المحافظة ا
                         lead of EGAD RiC-O team</dc:creator>4
                 <dc:creator xml:lang="en">International Council on Archives Expert Group on Archival 4
                          Description (ICA EGAD) </dc:creator> 4
                 <dc:publisher xml:lang="en">International Council on Archives</dc:publisher>ہا
                <dc:rights xml:lang="en">Copyright 2019-..., International Council on Archives
                          (ICA)</dc:rights>←
                <dcterms:abstract rdf:parseType="Literal">

4[16 lines]
                <dcterms:contributor rdf:resource="http://www.isni.org/000000039584825"/>u
                <dcterms:creator rdf:resource="https://data.bnf.fr/ark:/12148/cb169702205#about"/>
                <dcterms:description rdf:parseType="Literal">\u00e4[393 lines]
                 <dcterms:publisher rdf:resource="http://www.wikidata.org/entity/Q1421986"/>
                 <dcterms:title xml:lang="en">International Council on Archives Records in Contexts Ontology بالمراجعة المراجعة المرا
                           (ICA RiC-0) version 0.2</dcterms:title>4
                 <vann:preferredNamespacePrefix>rico</vann:preferredNamespacePrefix>+
                 <vann:preferredNamespaceUri>https://www.ica.org/standards/RiC/ontology#</vann:preferredNamespaceUri>
                 <rdfs:label xml:lang="en">International Council on Archives Records in Contexts Ontology 4
                          (ICA RiC-O) version 0.2</rdfs:label>4
                 <owl:priorVersion rdf:resource="https://www.ica.org/standards/RiC/RiC-0 v0-1.rdf"/>u
                 <owl:versionInfo xml:lang="en">Version 0.2 - 2021-02-12./owl:versionInfo>u
                 <skos:historyNote rdf:parseType="Literal">
µ
                          <html:div xml:lang="en">4
                                  <html:p>A first beta version of RiC-O was developed in 2017 and used by the National A
                                            Archives of France for building a proof of concept (<html:au
```

C'est un fichier XML conforme à OWL 2 (qui peut bien sûr être converti aisément dans d'autres formats de sérialisation de RDF, comme Turtle).

Utiliser au moins un éditeur XML pour l'ouvrir et le manipuler, ou, mieux, un **éditeur d'ontologies** comme Protégé.



#### Il y a plus de composants dans RiC-O que dans RiC-CM

Comme dans de nombreuses représentations formelles, techniques, d'un modèle, RiC-O est plus précise et plus riche que RiC-CM.


- Les entités RiC-CM y sont représentées par des classes
- D'autres classes ont été ajoutées pour pouvoir donner une définition plus précise d'une entité. Ainsi l'entité RiC-CM Place est représentée dans RiC-O par les classes Place, Physical Location et Coordinates
- La plupart des attributs dont le type de contenu est du texte libre sont des 'datatype properties' dans RiC-O (elles ont pour objet du texte). Par ex. *rico:history* ou *rico:scopeAndContent*
- Par ailleurs, certains attributs sont aussi représentés par des classes, lorsqu'on a besoin de leur assigner des propriétés donc de les considérer comme des objets à part entière. C'est le cas pour les attributs type qui ont des valeurs contrôlées dans RiC-CM. C'est aussi le cas pour les attributs Language, Name et Identifier de RiC-CM.
- Dans certains cas, pour assurer une certaine flexibilité au modèle et permettre de l'utiliser immédiatement, RiC-O propose plusieurs solutions de modélisation. C'est le cas pour les relations RiC-CM, qui sont représentées par des propriétés binaires dans RiC-O, mais aussi par un système de classes.

Des explications plus précises figurent ici: https://www.ica.org/standards/RiC/ontology.html#fromRiCCM-to-RiCO.

Nous donnons ci-après quelques précisions et exemples.




### Record resources et instantiations : l'exemple d'un acte dans un cartulaire





# Record resources et instantiations : l'exemple d'une série de photographies aériennes



ALEGORIA: métadonnées descriptives des photos de la cartothèque de la Reconstruction (alias cartothèque MRU) Apercu général du modèle de description. du fonds jusqu'au niveau des missions.

Les entités représentées sur fond rayé sont un exemple d'un nombre important d'entités de même nature.

Les entités représentées sur fond rose sont représentatives d'entités qui permettent de lier les données MRU avec celles de l'IGN

Au-dessous des rectangles, figurent quelques-unes des propriétés des entités ayant pour cible des valeurs textuelles,
sauf pour owit-sameAs et rdts-seeAlso (dont la cible est toujours un permailien vers la description classique de la ressource dans le SI des Archives nationales)

Les relations sont présentées uniquement dans un sens (les relations inverses existent mais ne figurent pas dans le diagramme).

@prefix tjai: <a href="mailto:shrtp://data.alegoria-project.fr/id/codes/ign/geotheque/typedejeuxdarchivesdimagerie/">heterois diagramme</a>).

@prefix rico: <a href="https://www.ica.org/standards/Ric/ontology#>.@prefix ari: <a href="https://data.alegoria-project.fr/id/ari/s-">https://data.alegoria-project.fr/id/ari/s-</a> Lorsqu'il n'y a pas de prefixe, le composant existe dans Ric-O.


@\_ <u>0</u>

© Archives nationales de France, décembre 2021

Document mis à disposition selon les termes
de la Creative Commons Attribution 4.0 International License



#### Record resources et instantiations : la description d'une photo dans la série de photographies



[Diagrammes tirés de la présentation faite le 16 décembre 2021 lors du séminaire de clôture du projet ANR ALEGORIA]



#### RiC-CM et RiC-O, des modèles flexibles

Il s'agit notamment de rendre RiC-O **immédiatement utilisable**. Par exemple :

- pour consigner **l'histoire d'une entité** (comme un Record), RiC-CM propose soit l'attribut RiC-A21 History, soit la relation RiC-R059i (*is or was affected by*) et une instance de l'entité Event. Dans RiC-O, c'est pareil, on a le choix.
- pour spécifier que telle entité (comme une activité) est régulée par un texte réglementaire officiel, RiC-CM propose la relation RiC-R063i (*is or was regulated by*) et une instance de l'entité Rule. Dans RiC-O, c'est pareil; mais on trouve aussi la propriété *rico:ruleFollowed* qu'on peut utiliser pour stocker du texte.
- pour consigner **l'appartenance d'une entité à une catégorie**, RiC-CM propose des attributs, comme, pour les documents, RiC-A17 Documentary Form Type. Dans RiC-O, on peut faire le même choix et se contenter de stocker du texte comme objet de la propriété *rico:type*. Mais on peut aussi choisir d'utiliser *rico:hasOrHadCategory* + une instance de la classe rico:Type (donc, par ex., un concept qui serait une instance de rico:DocumentaryFormType).
- Si on souhaite indiquer que **telle personne a dirigé tel groupe**, on trouvera dans RiC-CM la relation RiC-R042 *is or was leader of.* La même possibilité existe dans RiC-O, qui propose également de représenter cette relation sous la forme d'un graphe plus complexe, impliquant une instance de la classe rico:LeadershipRelation



#### Les 'types' dans RiC-O (1)

Dans RiC-CM, des attributs (comme Activity Type, Carrier Type, Corporate Body Type, Documentary Form Type, Event Type, Place Type, Record Set Type) permettent de catégoriser les entités. Leur valeur devrait normalement être prise dans des vocabulaires contrôlés.

Les concepts de tels vocabulaires sont des **points d'accès majeurs aux métadonnées**, et constituent potentiellement des **clés de liage essentielles** entre jeux de métadonnées archivistiques.

En RDF, le modèle de référence pour représenter un vocabulaire contrôlé est SKOS. Il permet de définir des concepts et les relations sémantiques (hiérarchiques ou associatives) qu'ils ont entre eux, ainsi que des relations d'alignement avec des concepts d'autres vocabulaires.

Il existe déjà des vocabulaires SKOS nationaux et internationaux pour certaines de ces notions (et d'autres vont voir le jour, en France par exemple ; on le souhaite en tout cas). Voir par exemple le thésaurus matières pour l'indexation des archives locales.



#### Les 'types' dans RiC-O (2)


Si l'on en fait une analyse scientifique fine, certaines notions au moins (ou les contenus de certains de ces vocabulaires) peuvent être considérées comme des entités historiques, ayant une histoire, voire des dates d'existence et une dimension spatiale, précédant ou suivant d'autres concepts. C'est le cas notamment pour rico:DocumentaryFormType ou rico:ActivityType. Le modèle SKOS n'inclut pas les propriétés nécessaires pour exprimer ces facettes contextuelles, historiques.

Afin de permettre, si et quand ce sera nécessaire, de décrire ces notions comme des entités historiques, **RiC-O définit donc ses propres classes, sous-classes de rico:Type, pour représenter les attributs de catégorisation de RiC-CM**.

Il est très simple d'articuler un vocabulaire SKOS existant avec une des classes RiC-O ainsi définie. Il suffit de spécifier que les concepts de ce vocabulaire sont aussi des instances de la classe RiC-O correspondante. RiC-O est accompagnée de l'embryon de deux vocabulaires, un pour les Record Set Type (types d'ensemble documentaire), un pour les Documentary Form Type (types de document).



#### Les 'types' dans RiC-O (3)



Exemple d'utilisation d'un type de document (rico:DocumentaryFormType), ici défini comme étant également un concept SKOS dans le référentiel des types de documents des Archives nationales

Les relations RiC-O sont présentées uniquement dans un sens (les relations inverses existent mais ne figurent pas dans le diagramme).

Le préfixe rico: indique que le composant (classe ou propriété) n'existe que dans RiC-O.

Lorsqu'il n'y a pas de préfixe, le composant existe dans RiC-OM et dans RiC-O.



© Archives nationales de France, février 2020

Document mis à disposition selon les termes
de la Creative Commons Attribution 4.0 International License



#### La modélisation des lieux dans RiC-O (1)

Les lieux dans RiC sont considérés, non pas comme des concepts, mais comme des **entités géo-historiques**.


RiC-O propose d'utiliser jusqu'à trois classes pour représenter un lieu, si besoin.

Ce modèle a été élaboré en s'inspirant d'autres modèles en cours d'élaboration, comme Linked Places Format.



#### La modélisation des lieux dans RiC-O (2)

Exemple ici avec la commune d'Ambérieux-en-Dombes (dans le référentiel des lieux des Archives nationales).



Description partielle, conforme à RiC-O, d'un lieu (la commune d'Ambérieux-en-Dombes) dans la version RDF du référentiel des lieux des Archives nationales.

Les relations sont présentées uniquement dans un sens (les relations inverses existent mais ne figurent pas dans le diagramme).

Le préfixe rico; indique que le composant (classe ou propriété) n'existe que dans RiC-O. Lorsqu'il n'y a pas de préfixe, le composant existe dans RiC-CM et dans RiC-O.



© Archives nationales de France, janvier 2021 Document mis à disposition selon les termes de la Creative Commons Attribution 4.0 International License

On aurait pu ajouter des relations vers les noms (instances de rico:PlaceName) de la commune, vers des lieux qui ont précédé cette commune, vers des lieux localisés dans cette commune... Et bien sûr, on peut ensuite spécifier, par exemple, des relations vers des agents dont le ressort ou le siège social est dans cette commune, ou des documents ayant cette commune pour sujet.



#### Les classes de relations dans RiC-O (1)

Une relation peut être considérée comme un objet à part entière, ayant par exemple une date et une description. C'est particulièrement vrai pour certaines relations dont la portée est importante en archivistique, comme les relations entre agents, ou celles entre agents et activités. Et dans de nombreux autres cas!

Exemple: « Jean-Noël Jeanneney (1942-....) a été président de Radio France et RFI de 1982 à 1986. »


En EAC-CPF (ISAAR-CPF) (adapté de la notice d'autorité 050789 des Archives nationales) :



#### Les classes de relations dans RiC-O (2)

Dans RiC-O, les 78 relations binaires définies dans RiC-CM sont présentes. Cependant, comme une propriété RDF (par ex. *rico:hasProvenance*, transposition de la relation RiC-R026 de RiC-CM) ne peut pas avoir d'attributs et qu'ici on a besoin notamment de décrire et de dater la relation, les relations sont aussi représentées comme des classes.

Cette méthode de modélisation permet aussi de connecter, à l'aide d'une telle relation, de nombreuses entités autres que la source et la cible d'une relation binaire. La relation binaire est alors par ailleurs formellement définie dans RiC-O comme un chemin simple, déclaré comme déductible, par inférence, de la combinaison de deux triplets dans lesquels une instance d'une classe Relation est centrale.





#### Feuille de route pour RiC-O 1.0

Ce qu'on peut déjà dire, c'est qu'il est prévu :

- des corrections, ajouts et ajustements ponctuels
- la prise en compte des modifications de RiC-CM 0.2
- une revue de la définition des object properties (ajout éventuel de caractéristiques, comme la transitivité)
- des mappings vers différents modèles (en commençant par PREMIS et Schema.org)
- des mappings EAD et EAC-CPF vers RiC-O
- la traduction en français d'au moins une partie des spécifications (labels des composants au minimum ; en cours)
- l'ajout de nouveaux exemples et diagrammes
- peut-être, une modularisation

Le travail devrait commencer dans les prochains jours. Il sera possible de le suivre en direct (voir les tickets ouverts et le développement dans des branches dédiées, dans le dépôt public).



#### De la théorie à la pratique : mises en œuvre connues de RiC-O

RiC-CM et RiC-O n'en sont qu'à leurs **débuts** et il y a peu d'implémentations de RiC-O. Voir la page RiC-O projects and tools qui sera mise à jour prochainement. Parmi les utilisateurs que le groupe EGAD connaît :


- dans des services d'archives: des outils en cours de développement par la société suisse Docuteam, éditeur de logiciels, et plus généralement plusieurs projets en Suisse; le service des archives de la ville d'Amsterdam, dont le futur système d'information sera fondé sur RiC-O et les technologies sémantiques (voir le blog du service ainsi que la thèse de M. Geerlings); une preuve de concept en cours d'élaboration aux Archives nationales de Singapour; et les Archives nationales de France (voir diapos suivantes)
- du côté des agrégateurs : la future version du portail FranceArchives ; le portail Memobase pour le patrmoine audiovisuel Suisse – voir aussi le schéma utilisé ; le projet Social Networks and Archival Context (SNAC) Cooperative
- du côté des projets de recherche : ALEGORIA ; ORESM (voir notamment la présentation d'une preuve de concept faite le 26 novembre 2021; un projet sur des archives d'architecte en Italie ; le projet de recherche allemand SONAR(idh) ; etc.]

Il est très probable qu'aucun projet ou institution n'utilise la totalité des composants RiC-CM ou a fortiori RiC-O. Ils en utiliseront un sous-ensemble, et l'étendront aussi sans doute (ajouteront des sous-classes et sous-propriétés pour satisfaire des besoins spécifiques).

Sommaire



# 4. *Records in Contexts* aux Archives nationales





### Au sujet de cette partie du cours

#### Voir notamment:

- l'article suivant (assez ancien maintenant) : Clavaud (Florence), « Transformer les métadonnées des Archives nationales en graphe de données : enjeux et premières réalisations », dans *Les Archives nationales, une refondation pour le XXIe siècle*, numéro spécial de La Gazette des Archives, n° 254 (2019-2), p. 59-88. Disponible sur Persée : 10.3406/gazar.2019.5857
- la présentation faite à Lausanne (Suisse) en décembre 2022, "Records in Contexts (RiC) aux Archives nationales de France : enjeux, réalisations, perspectives", lors d'une demi-journée consacrée à RiC et à ses premiers usages organisée par l'Association Vaudoise des Archivistes. La vidéo est également disponible ici. Présentation PDF chargée dans le dépôt sur GitHub.



# Les principales réalisations des Archives nationales jusqu'ici

- la preuve de concept PIAAF (février 2018)
- l'outil de conversion RiC-O Converter (version 1.0 réalisée et publiée en 2020)
- les référentiels sémantisés (en ligne sur GitHub depuis 2021)
- le démonstrateur mis en ligne en juin 2022, pour environ 59 millions de triplets décrivant le tiers des archives des notaires de Paris, soit 9 km d'archives (voir les deux interfaces de recherche et la documentation)



### Ce qui sera fait en 2023 aux Archives nationales (en ce qui concerne les outils et infrastructures)

- la mise à jour du logiciel RiC-O Converter pour convertir l'ensemble des fichiers EAD et EAC-CPF des AN en données RDF/RiC-O 0.2 (développements en cours ; version 2 sera publiée ce printemps)
- la poursuite des travaux entrepris depuis fin 2020 avec l'Inria pour disposer à terme d'algorithmes de reconnaissance d'entités nommées (machine learning) dans les fichiers EAD (projet NER4Archives ; voir la présentation faite en mars 2022)
- des spécifications et scénarios pour l'évolution du modèle de données et de l'infrastructure de gestion des référentiels
- probablement, des interfaces de recherche et de consultation pour divers graphes de connaissances, en commençant par les référentiels sémantisés



## Ce qui sera fait ou commencé en 2023 aux Archives nationales (en ce qui concerne les données)

- l'enrichissement et la mise à jour de la version sémantisée des référentiels, grâce à des travaux divers (création manuelle de nouvelles entrées ou alignement des données avec d'autres jeux de données en open data, notamment pour les lieux) ; leur publication, sous la forme de releases successives sur GitHub
- des travaux visant à améliorer la qualité des métadonnées source (fichiers EAD), donc du graphe de connaissances publié dans le démonstrateur Sparnatural (notamment réduction des redondances par fusion des descriptions multiples existant pour certains documents) - préfiguration de chaînes de traitement plus générales
- des travaux de rpduction et de sémantisation de nouvelles notices d'agents (référentiel national des notaires ; notices de hauts fonctionnaires de l'administration territoriale)
- la production d'une première version d'un référentiel des relations, basé sur l'existant aux AN, sur les besoins actuels et sur RiC
- les débuts de la mise en œuvre de RiC-CM et RiC-O sur les métadonnées de description des archives nativement numériques
- dans le cadre de divers projets, des travaux de modélisation, de production de données et de liage avec d'autres jeux de données (cas du projet ORESM)



### Tout cela, en attendant...

...une décision politique pour une mise en œuvre systématique des principes FAIR et la réalisation d'un data.archives-nationales.culture.gouv.fr (comme data.bnf.fr) permettant de passer à l'échelle, donc la définition d'une stratégie, incluant :

- la mise en œuvre de dispositifs d'assignation et de gestion d'identifiants pérennes pour l'ensemble des ressources à décrire ;
- l'intégration des dispositifs de production de données RDF dans le SI des AN;
- la mise en place d'un SPARQL endpoint et le développement d'une interface complète de recherche et de consultation pour les données RDF ;
- le développement d'APIs dédiées permettant aux machines d'accéder à distance aux métadonnées des AN;
- et plus globalement le décloisonnement des silos internes de métadonnées, le changement des infrastructures de stockage et de gestion, pour passer à une architecture orientée données ;
- des outils et programmes pour améliorer la qualité des métadonnées et passer à un modèle de graphe d'entités fondé sur RiC

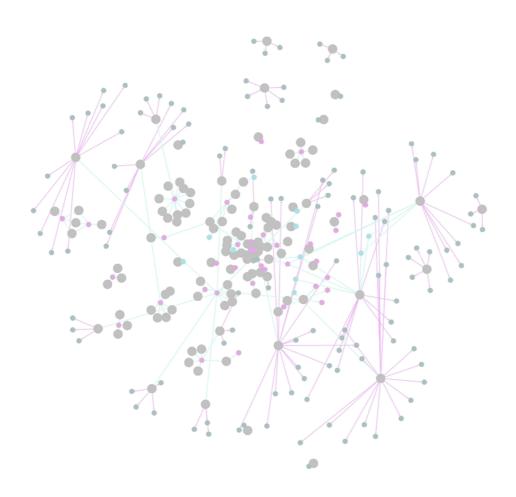
Les travaux d'élaboration de cetet stratégie vont démarrer cette année. Pour mener à bien cette transformation du système d'information, il faudra lui affecter les moyens financiers et humains adéquats.

Toutes ces actions s'inscrivent parfaitement dans la stratégie du ministère sur les données culturelles.

Sommaire



### 5. Exercices





## 5.1. Exercice 1 : étudier un petit instrument de recherche en EAD, du point de vue de RiC

Ouvrir le fichier XML/EAD nommé FRAN\_IR\_054848.xml

- il est consultable dans la salle des inventaires virtuelle des AN; son permalien est le suivant : https://www.siv.archives-nationales.culture.gouv.fr/siv/IR/FRAN\_IR\_054848.
- il est associé à la notice d'autorité (en EAC-CPF) FRAN\_NP\_005422.xml, dont la vue HTML est consultable via le permalien https://www.siv.archives-nationales.culture.gouv.fr/siv/NP/FRAN\_NP\_005422

Quelles **entités** RiC sont décrites dans ce fichier EAD ? Quelles propriétés ont ces entités ? Quelles **relations** existent entre ces entités ?

D'après cet unique exemple, quelles questions ou problématiques soulève le "passage à RiC" selon vous ?

Quelles réflexions ce petit exercice vous inspire-t-il ? Et si vous deviez, pour un service d'archives ou pour un projet fondé sur des métadonnées archivistiques, publier en RDF ces jeux de métadonnées, comment aborderiez-vous le sujet ?



### 5.2. Exercice 2 : utiliser le logiciel RiC-O Converter

Télécharger la dernière release de RiC-O Converter : https://github.com/ArchivesNationalesFR/rico-converter/releases/tag/v1.0.0.

#### Dézipper le dossier. On y trouve :

- dans le dossier 'documentation', un site web de documentation. Dans votre navigateur, ouvrir le fichier index.html qui est dans ce dossier. Vous y retrouvez notamment les mappings EAD et EAC vers RiC-O 0.1.
- dans le dossier unit-tests, les tests unitaires qui ont permis d'établir les spécifications détaillées du logiciel
- dans le dossier parameters, des fichiers de paramètres, adaptés au cas des AN, mais qui peuvent être modifiés
- dans le dossier input-ead, des fichiers EAD prêts à convertir
- idem dans le dossier input-eac

Dans un premier temps, exécuter la conversion des fichiers EAD (sur un ordinateur sous Windows, double-cliquer sur le fichier ricoconverter.bat et répondre 'convert\_ead' à la première question, puis retour chariot à la question suivante).

La conversion prend quelques secondes, le résultat est stocké dans le dossier output-ead-{AAAAMMJJ}.



#### Exercice 2, suite

Dans le dossier RDF de sortie, il y a un fichier RDF par instrument de recherche. Ouvrir le fichier FRAN\_RecordResource\_054848.rdf et le fichier EAD source (FRAN\_IR\_054848.xml) dans votre éditeur XML.

Des questions?

Faire la même chose pour les 101 fichiers EAC-CPF stockés dans le dossier input-eac. Dans le dossier RDF de sortie, on trouve 3 sous-dossiers, dont un pour les agents (101 fichiers RDF, un pour chaque entité décrite) et un pour les relations entre agents et les relations de provenance. Ouvrir le fichier FRAN\_Agent\_005422.rdf et le fichier EAC-CPF source.

Des questions?



#### Paramétrer la conversion

Pour cela on utilise les fichiers XML du dossier parameters

Ouvrir le fichier convert\_ead.properties

On y trouve des paramètres pour la gestion des fichiers à traiter et des fichiers générés, et des paramètres qui vont définir certaines caractéristiques des fichiers de sortie, comme le segment invariant de l'URI.

Si l'on veut vraiment modifier le comportement de RiC-O Converter pour l'adapter à un cas d'utilisation d'EAD différent de celui des AN, il faudra modifier les scripts de transformation. Pour cela, il faut être un bon développeur XSLT 2.0, ou trouver un tel développeur !

Comem déjà dit, les AN sont en train de développer, avec la société Sparna, une version 2 du logiciel. Elles vont par la suite continuer à enrichir le logiciel.

Une des pistes serait que RiC-O Converter prenne en compte aussi des fichiers XML/SEDA (le SEDA, Standard d'Echange de Données pour l'Archivage, schéma XML (transposé en norme AFNOR - NF Z440-22 « Modélisation des échanges de données pour l'archivage » - en janvier 2014, puis en mars 2018 en norme ISO - NF ISO 20614 « Protocole d'échange de données pour l'interopérabilité et la préservation ») qui définit le modèle de données des messages échangés lors du transfert d'un paquet d'archives numériques vers un système d'archivage électronique. Ces messages incluent impérativement les métadonnées de gestion et les métadonnées descriptives des archives transférées).



## 5.3. Exercice 3 : utiliser GraphDB Free et SPARQL pour faire des requêtes dans le RDF obtenu précédemment

On va utiliser le logiciel libre GraphDB Free https://www.ontotext.com/products/graphdb/.

Télécharger et installer le logiciel (version 'desktop installation'). Avant cela vous devrez remplir un formulaire et attendre d'avoir reçu un courriel.

Démarrer en cliquant sur l'icône du logiciel et aller à http://localhost:7200/

Créer un entrepôt RDF en quelques clics (c'est simple et la documentation vous aidera).

Importer dans cet entrepôt les données RDF produites pendant l'exercice précédent, ainsi que l'ontologie RiC-O (dans sa version 0.1, fournie dans le dépôt GitHub). Ce qui donne un total d'environ 828 000 triplets RDF (avec des règles d'inférence OWL 2).





#### Exercice 3, suite

Après avoir sélectionné l'entrepôt, on peut pour commencer explorer un peu :

- la hiérarchie des classes disponibles (Explore > Class hierarchy)
- les relations entre les entités décrites dans l'entrepôt (Explore > Class relationships)

#### Class relationships ©





Sommaire




#### **Exercice 3, suite : utiliser SPARQL**

Ouvrir le fichier de requêtes SPARQL 'SPARQL-RiC-O.txt'.

Choisir une requête, puis la copier/coller dans la fenêtre GraphDB > SPARQL

Enjoy comme on dirait en anglais!

## 6. Conclusion



#### Bilan

Est-ce que ce cours vous a intéressés ?

Des réactions, des suggestions, des questions?

#### À retenir :

- *février 2021* : publication de **RiC-O 0.2**
- *juillet 2021*: publication de **RiC-CM 0.2 full draft**, avec appel à commentaires
- printemps 2023: publication de RiC-CM et RiC-O v1.0
- sur RiC-O, vous pouvez utiliser l'entrepôt GitHub pour suggérer des améliorations ou soumettre des problèmes
- n'hésitez pas à me contacter!